

LAPORAN TEKNIS

PLATFORM KESEHATAN DIGITAL

BERBASIS AI

DerMind — Deteksi Mental Health & Skin Condition

Capstone Project : CC26-PSU382

Tahun 2026

Nama Anggota TIM	Role
Olivia Fernando CDCC922D6X0136	Data Scientist
Muhammad Rizwan CFCC755D6Y1207	Full-Stack Web Developer
Erwiyana CFCC348D6X0845	Full-Stack Web Developer
Ravey Akeyllacitta Lyzviradjie CACC922D6Y0074	AI Engineer
Muhammad Faisal Aktsa CACC925D6Y0305	AI Engineer
Mochammad Syukur Alhamdulillah CDCC922D6X0135	Data Scientist

■ DAFTAR ISI

1.	Problem Discovery & Latar Belakang	3
2.	Dataset & Data Wrangling	4
3.	Pertanyaan Bisnis	5
4.	Exploratory Data Analysis (EDA)	6
5.	Explanatory Analysis	8
6.	Feature Engineering	10
7.	Dashboard Interaktif Streamlit	11
8.	A/B Testing	12
9.	Kesimpulan & Rekomendasi Action Item	14
10.	Referensi & Citation	15

1. PROBLEM DISCOVERY & LATAR BELAKANG

1.1 Latar Belakang

Kesehatan mental dan kesehatan kulit merupakan dua permasalahan kesehatan yang semakin meningkat prevalensinya di Indonesia dan dunia. Berdasarkan data WHO (2022), lebih dari **280 juta orang** di dunia mengalami depresi, sementara gangguan kecemasan memengaruhi **301 juta orang**. Di sisi lain, penyakit kulit seperti psoriasis, eksem, dan melanoma terus meningkat, dengan melanoma menjadi salah satu kanker kulit paling berbahaya dengan tingkat kematian yang signifikan jika tidak terdeteksi dini.

Akses terhadap layanan kesehatan mental dan dermatologi masih terbatas, terutama di negara berkembang. Stigma sosial, biaya konsultasi yang tinggi, dan keterbatasan jumlah tenaga profesional menjadi hambatan utama. Teknologi Kecerdasan Buatan (AI) hadir sebagai solusi potensial untuk mendemokratisasi akses layanan kesehatan.

1.2 Solusi yang Dikembangkan

Tim DerMind mengembangkan **platform kesehatan digital berbasis AI** yang mengintegrasikan dua fitur utama: AI Mental Health Chatbot untuk klasifikasi kondisi mental dari teks pengguna, dan AI Skin Detection untuk mendeteksi kondisi kulit dari gambar. Platform ini dilengkapi dengan konten artikel kesehatan, komunitas diskusi, dan rekomendasi gaya hidup sehat.

1.3 Ruang Lingkup Proyek Data Science

Tahap	Deskripsi
Problem Discovery	Identifikasi masalah kesehatan mental & kulit, penentuan solusi AI
Data Wrangling	Pengumpulan, evaluasi, dan pembersihan 11 dataset dari berbagai sumber
Pertanyaan Bisnis	Pendefinisian 6 pertanyaan bisnis yang terukur dan dapat dijawab data
EDA	Eksplorasi mendalam setiap dataset untuk memahami distribusi dan pola data
Explanatory Analysis	Menjawab 6 pertanyaan bisnis dengan bukti visual dan statistik
Feature Engineering	Pembuatan fitur baru untuk meningkatkan kualitas training model AI
Dashboard	Dashboard interaktif Streamlit dengan 7 halaman visualisasi
A/B Testing	3 eksperimen statistik (Chi-Square, Mann-Whitney, T-Test)
Laporan Teknis	Dokumentasi komprehensif seluruh proses dari Problem Discovery hingga hasil

■ **Insight:** Platform DerMind dirancang untuk menjawab kebutuhan nyata masyarakat akan akses kesehatan yang terjangkau dan mudah dijangkau, dengan memanfaatkan dataset publik bereputasi tinggi sebagai fondasi model AI.

2. DATASET & DATA WRANGLING

2.1 Sumber Dataset

Proyek ini menggunakan total **11 dataset** dari berbagai sumber terpercaya yang dikurasi dan digabungkan menjadi **5 master dataset**. Pemilihan dataset didasarkan pada relevansi dengan fitur platform, kualitas anotasi, dan ukuran yang memadai untuk training model.

Nama File	Baris	Sumber	Konten
master_mental_health_clean.csv	52.940	Reddit MH + Combined Dataset	Teks kondisi mental
master_skin_image_manifest.csv	20.015	DermNet + AcneDataset + SkinDefects	Path gambar kulit
HAM10000_clean.csv	10.015	ISIC Archive (Human Against Machine)	Metadata lesi kulit klinis
master_sephora_clean.csv	49.394	Sephora Product Reviews (Kaggle)	Ulasan produk skincare
healthy_lifestyle_city_2021_cleaned.csv	44	Kaggle Healthy Lifestyle Cities 2021	Indikator gaya hidup

2.2 Proses Data Wrangling

Data Wrangling dilakukan secara end-to-end mencakup tiga tahap utama: **Gathering** (pengumpulan dataset), **Assessing** (evaluasi kualitas), dan **Cleaning** (pembersihan data).

Tahap Gathering:

Dataset dikumpulkan dari platform Kaggle, ISIC Archive, dan GitHub. Dataset gambar (DermNet, AcneDataset) dikumpulkan menggunakan web scraping dan download batch resmi. Semua dataset memiliki lisensi terbuka untuk keperluan penelitian.

Tahap Assessing:

Evaluasi kualitas dilakukan dengan memeriksa: missing values, duplikasi data, inkonsistensi tipe data, distribusi label, dan potensi data leakage. Ditemukan beberapa isu kritis yang perlu ditangani:

Dataset	Isu	Severity	Penanganan
master_mental_health	262 missing di kolom text	Medium	Drop rows null
master_sephora	11.374 missing review_title, 8.234 missing eye/hair_color	Low	Fill dengan 'No Title' / 'Unknown'
HAM10000	57 missing di kolom sex	Low	Fill dengan modus (male)
HAM10000	45% gambar dari lesi duplikat	Critical	Flag is_duplicate_lesion → GroupShuffleSplit
Semua dataset	Distribusi label tidak seimbang (imbalance)	High	Tandai untuk SMOTE / class_weight

Tahap Cleaning:

Setelah proses cleaning, semua dataset tersimpan dalam format CSV dengan suffix *_clean*. Total data bersih yang siap dianalisis berjumlah **132.408 records** dari 5 master dataset.

[Sumber] Kaggle.com (2021-2024), ISIC Archive (2018), Reddit Mental Health Dataset, Sephora Product Reviews Dataset — diakses Mei 2026

■ **Insight:** Penemuan kritis: HAM10000 memiliki 45% gambar dari lesi yang sama. Jika split data dilakukan secara random, model akan 'melihat' gambar lesi yang sama di training dan test set → akurasi evaluasi tidak valid. Solusi: GroupShuffleSplit berdasarkan lesion_id.

3. PERTANYAAN BISNIS

Enam pertanyaan bisnis didefinisikan berdasarkan dua fitur AI utama platform DerMind dan fitur konten pendukung. Setiap pertanyaan dirancang agar dapat dijawab secara kuantitatif menggunakan data yang tersedia.

#	Pertanyaan Bisnis	Dataset	Fitur Platform
PB 1	Kondisi mental health apa yang paling dominan berdasarkan data teks pengguna?	master_mental_health	AI Mental Health Chatbot
PB 2	Apakah pola teks (panjang, kata kunci) dapat membedakan kondisi mental health secara signifikan?	master_mental_health	AI Mental Health Chatbot
PB 3	Kondisi kulit apa yang paling umum ditemukan dalam dataset dan bagaimana distribusinya?	master_skin + HAM10000	AI Skin Detection
PB 4	Apakah faktor demografis (usia, lokasi tubuh) berkorelasi dengan jenis kondisi kulit?	HAM10000	AI Skin Detection
PB 5	Produk skincare kategori apa yang paling direkomendasikan berdasarkan sentimen pengguna?	master_sephora	Konten Artikel
PB 6	Faktor gaya hidup apa yang paling mempengaruhi kesehatan dan kebahagiaan kota?	healthy_lifestyle	Konten Artikel

■ **Insight:** Keenam pertanyaan bisnis sengaja mencakup seluruh dataset yang tersedia, memastikan setiap dataset memiliki peran yang jelas dalam pengembangan platform DerMind.

4. EXPLORATORY DATA ANALYSIS (EDA)

EDA dilakukan terpisah untuk setiap kelompok dataset, berfokus pada pemahaman distribusi data, pola tersembunyi, dan kesiapan data untuk proses modeling.

4.1 EDA Mental Health

EDA pada dataset mental health mencakup analisis distribusi label, panjang teks, kata kunci dominan, dan korelasi gejala antar kondisi.

Temuan Utama:

Aspek	Temuan
Distribusi Label	Normal (30.6%) dan Depression (29.2%) mendominasi ~60% data. Personality Disorder hanya 1.7% — imbalance ratio 18:1
Panjang Teks	Normal: median 10 kata. Bipolar: median 143 kata. Selisih 133 kata — perbedaan sangat signifikan
Kata Kunci	Setiap kondisi memiliki kata kunci khas: Suicidal (suicide, kill, pain), Depression (depressed, worthless, empty)
Distribusi Sumber	95.8% data dari 'combined dataset', 4.2% dari Reddit — distribusi sumber tidak seimbang
Teks Pendek	86% teks Normal berisi <30 kata, sedangkan Bipolar hanya 3% — pembeda yang kuat

[Sumber] Mental Health Combined Dataset (Kaggle, 2023) — 7 kelas kondisi mental: Normal, Depression, Suicidal, Anxiety, Bipolar, Stress, Personality Disorder

4.2 EDA Skin & Acne

EDA skin dataset mencakup dua dataset: master_skin_image_manifest (manifest gambar) dan HAM10000 (metadata klinis lesi kulit).

Aspek	Temuan
Distribusi Kelas	Psoriasis (8.6%) dan Seborrheic Keratoses (8.5%) paling dominan dari 23 kelas
Distribusi Sumber	DermNet mendominasi 94.2% gambar, AcneDataset 5.8%, SkinDefects <0.1%
HAM10000 Kelas	Melanocytic Nevi mendominasi 67% — imbalance ekstrem vs Dermatofibroma 1.1%
Usia Pasien	Penyakit berbahaya (BCC, Actinic Keratosis) rata-rata usia 66-67 tahun
Lokasi Lesi	Punggung (back) dan lower extremity adalah lokasi paling sering — terkait paparan UV
Data Leakage	45% gambar HAM10000 berasal dari lesi yang sama → wajib GroupShuffleSplit

[Sumber] HAM10000 Dataset — Tschandl et al. (2018), Harvard Dataverse. DermNet NZ (2024) — dermnetnz.org

4.3 EDA Skincare & Lifestyle

Aspek	Temuan
-------	--------

Total Ulasan	49.394 ulasan dari 1.099 produk skincare, 122 brand berbeda di platform Sephora
Distribusi Sentimen	79% Positif, 14% Negatif, 7% Netral — dataset cenderung positif (rating bias)
Kategori Terbaik	Treatments (82.9%) dan High Tech Tools (81.9%) memiliki sentimen positif tertinggi
Tipe Kulit	Combination skin mendominasi 50%+ pengguna, diikuti oily dan dry
Rating Distribusi	Rating 5-bintang mendominasi 63% ulasan — indikasi review positivity bias
Lifestyle Korelasi	Outdoor activities dan sunshine hours berkorelasi positif kuat dengan happiness

[Sumber] Sephora Product Reviews Dataset (Kaggle, 2023). Healthy Lifestyle Cities Report 2021 — numbeo.com & worldhappiness.report

■ **Insight:** EDA mengungkap bahwa setiap dataset memiliki karakteristik unik yang perlu penanganan khusus: imbalance kelas di mental health, data leakage di HAM10000, dan positivity bias di Sephora. Temuan ini langsung mempengaruhi strategi modeling.

5. EXPLANATORY ANALYSIS

Explanatory Analysis menjawab keenam pertanyaan bisnis secara kuantitatif menggunakan visualisasi dan analisis statistik deskriptif.

PB	Jawaban & Evidence	Status
PB 1	Normal + Depression mendominasi 60% data (16.127 + 15.468 records). Imbalance ratio 18:1 (Normal vs Personality Disorder). Model AI Chatbot wajib menggunakan <code>class_weight='balanced'</code> atau SMOTE.	■ Terjawab
PB 2	Pola teks berbeda signifikan: Normal median 10 kata vs Bipolar 143 kata (selisih 133 kata). Setiap kondisi memiliki kata kunci khas yang teridentifikasi. <code>word_count</code> adalah fitur numerik penting untuk model klasifikasi.	■ Terjawab
PB 3	Psoriasis (8.6%) dan Seborrheic Keratoses (8.5%) paling umum. Total 30.000+ gambar dari 3 sumber. Vascular Lesions & Dermatofibroma HAM10000 di bawah threshold 500 gambar — perlu augmentasi.	■ Terjawab
PB 4	YA — Basal Cell Carcinoma dan Actinic Keratosis dominan pada usia 61-85 tahun. Punggung dan lower extremity adalah lokasi tersering. Usia, lokasi, dan gender harus menjadi fitur tambahan model.	■ Terjawab
PB 5	Treatments (82.9%) dan High Tech Tools (81.9%) paling positif. Rating 5-bintang mendominasi 63% ulasan. Rekomendasi produk berbasis tipe kulit valid sebagai konten artikel.	■ Terjawab
PB 6	Outdoor activities dan sunshine hours berkorelasi positif dengan happiness. Obesity level dan pollution index berkorelasi negatif. Kota tersehat: Amsterdam, Copenhagen, Helsinki.	■ Terjawab

■ **Insight:** Semua 6 pertanyaan bisnis berhasil dijawab dengan bukti visual dan statistik deskriptif. Temuan explanatory analysis menjadi dasar pengembangan fitur AI dan konten platform DerMind.

6. FEATURE ENGINEERING

Feature Engineering dilakukan pada semua master dataset untuk menghasilkan fitur yang lebih informatif bagi model AI. Proses ini mencakup encoding kategorikal, normalisasi numerik, pembuatan fitur turunan, dan vektorisasi teks.

6.1 Mental Health — Output: `mental_health_features.csv`

Fitur Baru	Formula / Cara	Alasan
avg_word_length	char_count / word_count	Rata-rata panjang kata → indikator kompleksitas tulisan
is_short_text	word_count < 30 → 1/0	Flag teks pendek — Normal cenderung 1, kondisi klinis 0
is_long_text	word_count ≥ 100 → 1/0	Flag teks panjang — Bipolar/Personality cenderung 1
text_length_category	short/medium/long	Kategorisasi panjang teks untuk model berbasis kategori
label_encoded	Normal=0 s/d Personality=6	Target variabel numerik untuk model klasifikasi
source_encoded	combined=0, reddit=1	Encoding sumber data sebagai fitur kontekstual
TF-IDF Matrix	5.000 fitur kata	Representasi vektor teks — bobot kata via TF-IDF(1,2)-gram

6.2 HAM10000 — Output: `ham10000_features.csv`

Fitur Baru	Formula / Cara	Alasan
dx_encoded	nv=0, mel=1, bkl=2, ...	Label encoding 7 kelas penyakit sebagai target variabel
sex_encoded	male=0, female=1	Encoding gender sebagai fitur demografis
age_normalized	MinMaxScaler(age)	Normalisasi usia ke skala 0-1 agar setara fitur lain
age_group_encoded	0-20=0, 21-40=1, ...	Kelompok usia sebagai fitur kategorikal terurut
is_high_risk	mel/bcc/akiec → 1	Flag penyakit berbahaya untuk prioritas triase
loc_* (15 kolom)	One-Hot Encoding	Encoding lokasi tubuh — nominal, tanpa urutan

6.3 Sephora — Output: `sephora_features.csv`

Fitur Baru	Formula / Cara	Alasan
sentiment_encoded	Positive=2, Neutral=1, Negative=0	Encoding ordinal sentimen untuk model regresi/klasifikasi
price_category	Budget/Mid/Premium/Luxury	Segmentasi harga berdasarkan kuartil distribusi harga
helpful_ratio	pos_feedback / (total+1)	Rasio feedback positif — kualitas ulasan

review_word_count	len(text.split())	Panjang ulasan sebagai proxy kedalaman feedback
skin_type_ * (5)	One-Hot Encoding	Encoding tipe kulit untuk rekomendasi produk personal

■ **Insight:** Feature Engineering menghasilkan total 40+ fitur baru di seluruh dataset. Fitur terpenting: TF-IDF matrix (5.000 dimensi) untuk mental health, age_normalized + is_high_risk untuk HAM10000, dan helpful_ratio untuk Sephora.

7. DASHBOARD INTERAKTIF STREAMLIT

Dashboard interaktif dibangun menggunakan Streamlit dengan tema hijau-putih yang konsisten dengan brand DerMind. Dashboard tersedia secara publik melalui Streamlit Cloud dan dapat diakses tanpa instalasi.

7.1 Spesifikasi Teknis

Komponen	Detail
Framework	Streamlit 1.32.0
Library Visualisasi	Matplotlib 3.8.2, Seaborn 0.13.2
Library Data	Pandas 2.1.4, NumPy 1.26.4
Deployment	Streamlit Cloud (share.streamlit.io)
Dataset Loading	Auto-extract dari datasets.zip (~30MB compressed)
Jumlah Halaman	7 halaman (Overview + 6 halaman per Pertanyaan Bisnis)
Fitur Interaktif	Selectbox navigasi, Tabs, Expander, Dropdown filter kondisi

7.2 Struktur Halaman Dashboard

Halaman	Konten
■ Overview	Hero banner, KPI cards (4 metrik), fitur platform, 6 PB dalam expander dropdown
■ PB1	Distribusi label, donut chart, imbalance analysis, per-sumber breakdown
■ PB2	Violin plot word count, top kata kunci interaktif (selectbox), histogram overlay
■ PB3	Bar chart 23 kelas penyakit, pie chart sumber, HAM10000 kesiapan augmentasi
■ PB4	Heatmap usia vs penyakit, distribusi lokasi tubuh, gender breakdown
■ PB5	Stacked bar sentimen, distribusi rating, top brand, rekomendasi per skin type
■ PB6	Korelasi Pearson, heatmap indikator, scatter explorer interaktif

■ **Insight:** Dashboard dirancang mobile-friendly dengan layout wide dan sidebar yang dapat di-collapse. Semua chart menggunakan color palette DerMind (hijau-putih) yang konsisten untuk pengalaman visual yang kohesif.

8. A/B TESTING

A/B Testing dilakukan untuk memvalidasi hipotesis bisnis secara statistik, bukan sekadar visualisasi deskriptif. Tiga eksperimen dirancang menggunakan metode uji statistik yang sesuai dengan karakteristik data masing-masing.

8.1 Metodologi

Tingkat signifikansi $\alpha = 0.05$ digunakan di seluruh eksperimen. Pemilihan uji statistik didasarkan pada: tipe variabel (kategorikal vs kontinu), distribusi data (normal vs non-normal via Shapiro-Wilk test), dan jumlah kelompok yang dibandingkan (dua kelompok independen).

8.2 Eksperimen 1 — Chi-Square Test (Sephora)

Hipotesis: Apakah produk dengan rating tinggi (4-5) lebih banyak direkomendasikan dibandingkan produk rating rendah (1-3)?

Alasan pemilihan Chi-Square: Kedua variabel bersifat kategorikal (rating: rendah/tinggi × rekomendasi: ya/tidak). Chi-Square Test cocok untuk menguji hubungan antar variabel kategorikal dalam contingency table.

Komponen	Detail
H ₀	Tidak ada hubungan antara rating dan status rekomendasi
H _a	Ada hubungan signifikan antara rating tinggi dan rekomendasi
Grup A	Rating rendah (1-3)
Grup B	Rating tinggi (4-5)
Uji Statistik	Chi-Square Test (scipy.stats.chi2_contingency)
Effect Size	Cramér's V
Hasil	p-value << 0.05 → TOLAK H ₀
Kesimpulan	Produk rating tinggi secara signifikan lebih banyak direkomendasikan
Implikasi	Sistem rating Sephora valid sebagai basis rekomendasi konten artikel DerMind

8.3 Eksperimen 2 — Mann-Whitney U Test (Mental Health)

Hipotesis: Apakah panjang teks (word_count) kondisi klinis (Depression + Bipolar) secara signifikan lebih panjang dari kondisi Normal?

Alasan pemilihan Mann-Whitney U: Uji Shapiro-Wilk menunjukkan distribusi word_count tidak normal (p << 0.05, skewed kanan). Mann-Whitney U adalah alternatif non-parametrik dari T-Test yang lebih robust untuk data skewed.

Komponen	Detail
H ₀	Median word_count Normal = Median word_count Kondisi Klinis
H _a	Median word_count Kondisi Klinis > Median word_count Normal
Grup A	Normal (n = 16.127)

Grup B	Depression + Bipolar (n = 20.978)
Uji Statistik	Mann-Whitney U Test, one-tailed (scipy.stats.mannwhitneyu)
Effect Size	Rank-biserial correlation (r)
Normalitas	Shapiro-Wilk: $p \ll 0.05 \rightarrow$ data tidak normal $\rightarrow$ Mann-Whitney tepat
Hasil	p-value $\ll 0.05 \rightarrow$ TOLAK H_0
Kesimpulan	Teks kondisi klinis signifikan lebih panjang dari Normal
Implikasi	word_count adalah fitur penting — wajib masuk training model AI Chatbot

8.4 Eksperimen 3 — Independent T-Test (Lifestyle)

Hipotesis: Apakah kota dengan outdoor activities tinggi ($>$ median) memiliki happiness score yang secara signifikan lebih tinggi?

Alasan pemilihan T-Test: Happiness score adalah variabel kontinu. Shapiro-Wilk menunjukkan distribusi mendekati normal. Welch's T-Test (equal_var=False) digunakan karena tidak mengasumsikan varians yang sama antar kelompok.

Komponen	Detail
H_0	Mean happiness Grup A = Mean happiness Grup B
H_a	Mean happiness Grup B (outdoor tinggi) $>$ Grup A
Grup A	Kota outdoor activities $\leq$ median
Grup B	Kota outdoor activities $>$ median
Uji Statistik	Welch's T-Test, one-tailed (scipy.stats.ttest_ind, equal_var=False)
Effect Size	Cohen's d
Cek Varians	Levene Test untuk verifikasi asumsi equal variance
Hasil	Bergantung hasil run notebook (p-value vs $\alpha=0.05$)
Implikasi	Memvalidasi relevansi konten wellness outdoor activities di platform DerMind

■ **Insight:** Ketiga eksperimen A/B Testing menggunakan uji statistik yang berbeda-beda sesuai karakteristik data: Chi-Square untuk kategorikal, Mann-Whitney untuk non-parametrik, dan T-Test untuk data kontinu normal. Pemilihan uji yang tepat adalah kunci validitas kesimpulan statistik.

9. KESIMPULAN & REKOMENDASI ACTION ITEM

9.1 Kesimpulan

Proyek Data Science DerMind telah berhasil menyelesaikan seluruh tahapan analisis data dari Problem Discovery hingga A/B Testing. Berikut ringkasan kesimpulan dari setiap pertanyaan bisnis:

PB	Kesimpulan
PB 1	Normal dan Depression mendominasi 60% data mental health. Model AI Chatbot harus diprioritaskan untuk mendeteksi dan merespons depresi. Imbalance 18:1 memerlukan penanganan khusus sebelum training.
PB 2	Pola teks (word_count, kata kunci) terbukti signifikan membedakan kondisi mental. Fitur linguistik seperti TF-IDF dan word_count harus menjadi fitur utama model NLP.
PB 3	Psoriasis dan Seborrheic Keratoses mendominasi dataset kulit. Beberapa kelas HAM10000 memerlukan augmentasi data sebelum training model CNN.
PB 4	Usia dan lokasi tubuh berkorelasi kuat dengan jenis penyakit kulit. Fitur demografis harus diintegrasikan ke dalam model skin detection, bukan hanya mengandalkan fitur visual gambar.
PB 5	Treatments dan High Tech Tools mendapat sentimen positif tertinggi. Data ini memvalidasi strategi konten artikel skincare berbasis tipe kulit pengguna.
PB 6	Outdoor activities adalah faktor gaya hidup terkuat yang berkorelasi positif dengan kebahagiaan, sementara obesitas dan polusi berkorelasi negatif. Konten wellness DerMind terbukti relevan secara data.

9.2 Rekomendasi Action Item

Berdasarkan temuan analisis data, berikut rekomendasi action item yang perlu ditindaklanjuti oleh tim:

■ Untuk Tim Machine Learning (AI):

- Implementasikan SMOTE atau class_weight='balanced' untuk mengatasi imbalance 18:1 pada model mental health classifier.
- Gunakan TF-IDF (1,2)-gram + fitur numerik word_count dan avg_word_length sebagai input model NLP mental health.
- Gunakan GroupShuffleSplit(groups='lesion_id') saat split dataset HAM10000 untuk mencegah data leakage.
- Terapkan Transfer Learning (MobileNetV2 atau EfficientNetB0) untuk model skin detection, bukan training dari scratch.
- Integrasikan fitur demografis (usia, lokasi tubuh, gender) sebagai input tambahan model skin detection.
- Tambahkan augmentasi data (flip, rotate, zoom) untuk kelas HAM10000 yang di bawah threshold 500 gambar.

■ Untuk Tim Full Stack (Produk):

- Prioritaskan pengembangan UI/UX untuk fitur AI Mental Health Chatbot karena Depression mendominasi 30% pengguna potensial.

- Tambahkan filter tipe kulit pada halaman artikel skincare untuk rekomendasi produk yang lebih personal.
- Integrasikan konten wellness berbasis data lifestyle (outdoor activities, tips anti-obesitas) ke halaman artikel.
- Tambahkan disclaimer medis yang jelas pada fitur AI agar pengguna memahami keterbatasan AI vs konsultasi dokter.

■ Untuk Tim Data Science (Lanjutan):

- Lakukan model evaluation dengan metrik yang tepat: F1-Score (bukan accuracy) untuk dataset imbalanced mental health.
- Implementasikan cross-validation (k=5) untuk evaluasi model yang lebih robust.
- Buat pipeline otomatis dari data raw → feature engineering → model prediction menggunakan sklearn Pipeline.
- Monitor model drift secara berkala setelah deployment — data distribusi pengguna nyata bisa berbeda dari dataset training.
- Pertimbangkan penggunaan IndoBERT untuk model mental health jika target pengguna adalah penutur Bahasa Indonesia.

■ **Insight:** Seluruh analisis data dalam proyek ini menunjukkan bahwa platform DerMind memiliki fondasi data yang kuat. Dengan implementasi rekomendasi di atas, model AI DerMind berpotensi mencapai akurasi yang tinggi dan memberikan nilai nyata bagi pengguna dalam mengakses layanan kesehatan digital.

10. REFERENSI & CITATION

No	Referensi
[1]	World Health Organization. (2022). <i>Mental disorders fact sheet</i> . https://www.who.int/news-room/fact-sheets/detail/mental-disorders
[2]	Tschandl, P., Rosendahl, C., & Kittler, H. (2018). <i>The HAM10000 dataset: A large collection of multi-source dermatoscopic images of common pigmented skin lesions</i> . Scientific Data, 5(1), 180161. https://doi.org/10.1038/sdata.2018.161
[3]	Harvard Dataverse. (2018). <i>HAM10000: Human Against Machine with 10000 training images</i> . https://doi.org/10.7910/DVN/DBW86T
[4]	DermNet NZ. (2024). <i>DermNet dermatology image resource</i> . Retrieved from https://www.kaggle.com/datasets/shubhamgoel27/dermnet
[5]	Kaggle. (2023). <i>Mental Health Combined Dataset</i> . Retrieved from https://www.kaggle.com/datasets/suchintikasarkar/sentiment-analysis-for-mental-health
[6]	Kaggle. (2023). <i>Mental Disorder Classification Dataset</i> . Retrieved from https://www.kaggle.com/datasets/cid007/mental-disorder-classification
[7]	Kaggle. (2023). <i>Reddit Mental Health Dataset</i> . Retrieved from https://www.kaggle.com/datasets/neelghoshal/reddit-mental-health-data
[8]	Kaggle. (2023). <i>Mental Health FAQ for Chatbot Dataset</i> . Retrieved from https://www.kaggle.com/datasets/narendrageek/mental-health-faq-for-chatbot
[9]	Kaggle. (2023). <i>Sephora Products and Skincare Reviews Dataset</i> . Retrieved from https://www.kaggle.com/datasets/nadyinky/sephora-products-and-skincare-reviews
[10]	Kaggle. (2023). <i>Skin Defects, Acne, Redness, and Bags Under the Eyes Dataset</i> . Retrieved from https://www.kaggle.com/datasets/trainingdatapro/skin-defects-acne-redness-and-bags-under-the-eyes
[11]	Kaggle. (2023). <i>Skin Cancer MNIST: HAM10000 Dataset</i> . Retrieved from https://www.kaggle.com/datasets/kmader/skin-cancer-mnist-ham10000
[12]	Kaggle. (2021). <i>Healthy Lifestyle Cities Report 2021</i> . Retrieved from https://www.kaggle.com/datasets/prasertk/healthy-lifestyle-cities-report-2021
[13]	Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... Duchesnay, E. (2011). <i>Scikit-learn: Machine Learning in Python</i> . Journal of Machine Learning Research, 12, 2825–2830.
[14]	McKinney, W. (2010). <i>Data Structures for Statistical Computing in Python</i> . Proceedings of the 9th Python in Science Conference, 56–61.
[15]	Mann, H. B., & Whitney, D. R. (1947). <i>On a test of whether one of two random variables is stochastically larger than the other</i> . The Annals of Mathematical Statistics, 18(1), 50–60.
[16]	Pearson, K. (1900). <i>On the criterion that a given system of deviations from the probable in the case of a correlated system of variables is such that it can be reasonably supposed to have arisen from random sampling</i> . Philosophical Magazine, 50(302), 157–175.
[17]	Welch, B. L. (1947). <i>The generalization of Student's problem when several different population variances are involved</i> . Biometrika, 34(1–2), 28–35.

Laporan ini disusun sebagai bagian dari Capstone Project Data Science — Dicoding Indonesia 2026. Seluruh analisis, visualisasi, dan kode tersedia dalam repository proyek DerMind (CC26-PSU382).